Сколтех LARSS Deep Learning School

Можно ли доверять ИИ?

Прагматичный подход к галлюцинациям LLM

Алексей Зайцев
Доцент Сколтеха, руководитель лаборатории LARSS

Reading Group #6 15 октября 2026 19:00 Мск

Алексей Зайцев и лаборатория LARSS



Алексей Зайцев
Доцент Сколтеха
Кандидат физ.-мат. наук
Руководитель LARSS

Надёжное машинное обучение

Неопределённость и детекция ошибок.
Модели последовательностей и временных рядов.
Генеративные модели и прикладные исследования.

sites.skoltech.ru/larss



Результаты по теме доклада

ACL 2026 · TOHA
Детекция через топологию attention-графов.

EMNLP 2026 · INTRYGUE
Механистическая коррекция энтропии в RAG.

ICML 2026 · совместная position paper
Байесовские принципы организации агентных систем.

2026 · препринт
Оценка риска до генерации ответа.

Профиль А. Зайцева; LARSS; TOHA, ACL 2026; INTRYGUE, EMNLP 2026; Bayesian orchestration, ICML 2026.

От ошибки модели к решению системы

01	Что считать галлюцинацией и как измерять риск	12 мин
02	Неопределённость, согласованность и скрытые состояния	18 мин
03	Внутренние механизмы: TOHA и INTRYGUE	27 мин
04	Надёжные системы и байесовские агенты	13 мин

Обсуждение

Ещё около 20 минут. Вопросы можно задавать по ходу.

Что должно означать «доверять»?

Можно ли использовать **этот ответ**
для **этого действия**?

- Ошибка в черновике письма и ошибка в решении агента имеют разную цену.
- Убедительный стиль ответа плохо измеряет его надёжность.
- Полезный детектор помогает решить, когда ответить, проверить или остановиться.

Оценка риска нужна вместе с правилом действия

Под словом «галлюцинация» скрыты разные ошибки

Что нарушено	Учебный пример	С чем сравниваем
Факты	«Столица Австралии — Сидней»	Проверяемое знание о мире
Входные данные	В таблице 12 заказов, в отчёте 21	Данные пользователя
Контекст RAG	Источник говорит о росте, ответ — о падении	Предоставленные документы
Ссылки на источники	Факт верен, но цитата его не подтверждает	Конкретный фрагмент источника

Factuality — истинность утверждения.

Faithfulness — соответствие входу и источникам.

Niu et al. RAGTruth. ACL 2024.

RAG: контекст есть, но ошибка остаётся

$P = (Q, C)$ — вход модели: запрос Q и найденный контекст C.

Запрос Q

«Чем отличаются газовое отопление и отопление на жидком топливе?»

Контекст C

Срок службы оборудования на жидком топливе — **30 лет и более**;
газовой печи — **11–14 лет**.

Ответ R

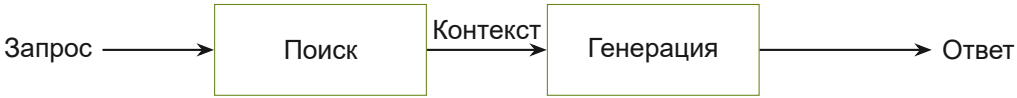
«Оборудование на жидком топливе обычно имеет **меньший** срок службы».

Faithfulness hallucination: ответ противоречит контексту

Grounded-ответ согласован с контекстом; сам контекст тоже может ошибаться.

Пример: Kuleshova et al. INTRYGUE: Induction-Aware Entropy Gating for Reliable RAG Uncertainty Estimation. EMNLP 2026.

Где возникают ошибки в RAG



Не нашли нужный факт
Нашли устаревший источник

Не использовали источник
Добавили неподтверждённое

Диагностика должна различать причины

Повторный поиск полезен при нехватке данных. Проверка цитат — при проблеме с обоснованием ответа.

Niu et al. RAGTruth. ACL 2024.

Почему модель может уверенно выдумывать?

$$\mathcal{L}_{\text{LM}} = -\sum_{t} \log p_\theta(x_t \mid x_{<t})$$

Предобучение

Предсказываем следующий токен, обычно без явной метки истинности.

Редкие и произвольные факты

По стилю текста нельзя восстановить любую дату, фамилию или точную цитату.

Стимул угадывать

При оценке только по accuracy отказ может проигрывать догадке.

Нужно оценивать и ошибки, и обоснованные отказы

Kalai et al. Why Language Models Hallucinate. 2025.

RAGTruth: проверяем отдельные утверждения

Около 18 тысяч ответов с разметкой неподтверждённых фрагментов

Задачи: ответы на вопросы, суммаризация и описание структурированных данных.

Уровень токена / фрагмента

Где именно появилось неподтверждённое утверждение?

Уровень ответа

Есть ли в ответе хотя бы одна галлюцинация?

Уровень системы

Можно ли показать этот ответ пользователю без проверки?

Niu et al. RAGTruth. ACL 2024.

Детектор выдаёт score, решение требует порога

$$R \sim p_\theta(\cdot \mid P), \qquad s(P, R) \in \mathbb{R}$$

Ранжирование

Чем выше s, тем подозрительнее ответ.

AUROC измеряет, как часто ошибочный ответ получает больший score, чем корректный.

Решение

При $s > \tau$ проверяем или отказываемся.

Порог τ зависит от задачи, цены ошибки и доступного бюджета.

Score 0.8 сам по себе не означает 80% вероятности ошибки.

Для системы важны risk и coverage

$$\text{coverage}(\tau) = \Pr(s \le \tau), \qquad \text{risk}(\tau) = \Pr(\text{error} \mid s \le \tau).$$

Учебный пример: 100 запросов	Ответили	Ошиблись	Risk
Без фильтра	100	20	20%
С порогом детектора	60	3	5%

Потеряли часть ответов, снизили риск среди оставшихся.

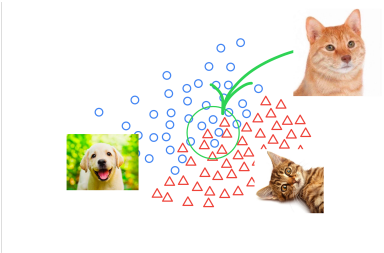
Дополнительно

Precision–recall, калибровка, задержка, стоимость и перенос.

Неопределённость: чего именно мы не знаем?

Aleatoric

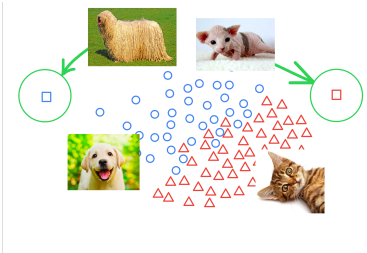
Неоднозначность наблюдений или самой задачи.



«Он увидел ключ»: без контекста возможны разные смыслы.

Epistemic

Недостаток знаний, данных или точность модели.



Вопрос о событии, которого нет в доступных источниках.

Иллюстрации: курс А. Зайцева, Lecture 11: UQ–Hallucination detection. Примеры адаптированы.

Байесовская формула связывает два источника

$$p(y \mid x, D) = \int p(y \mid x, \theta)\, p(\theta \mid D)\, d\theta$$

D — обучающие данные, θ — неизвестные параметры модели.

$$\underbrace{\mathrm{Var}(y \mid x, D)}_{\text{общая неопределённость}} = \underbrace{\mathbb{E}_{\theta \mid D}\, \mathrm{Var}(y \mid x, \theta)}_{\text{неопределённость данных}} + \underbrace{\mathrm{Var}_{\theta \mid D}\, \mathbb{E}(y \mid x, \theta)}_{\text{неопределённость модели}} .$$

Для регрессии это точное разложение дисперсии в выбранной модели.

Для LLM важен следующий вопрос

Какие практические сигналы приближают нужную нам неопределённость?

Адаптировано из Lecture 11: UQ–Hallucination detection.

Ансамбли приближают распределение предсказаний

$$p(y \mid x, D) \approx \frac{1}{M} \sum_{m=1}^{M} p(y \mid x, \theta_m).$$

Разные параметры могут давать разные ответы на один вход.

Плюс

Несогласие моделей даёт дополнительный сигнал.

Цена

Несколько моделей или проходов, память и задержка.

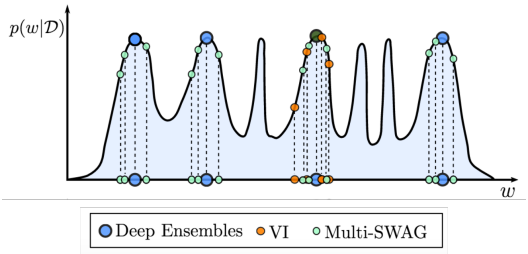


Иллюстрация различных приближений posterior.

Figure source: Wilson, Izmailov. Bayesian Deep Learning and a Probabilistic Perspective of Generalization. NeurIPS 2020. Из Lecture 11.

Один ответ: вероятность и энтропия токенов

$$p_t(v) = p_\theta(v \mid P, r_{<t}), \qquad e_t = -\sum_{v \in \mathcal{V}} p_t(v) \log p_t(v).$$

Средний NLL	$-\frac{1}{n}\sum_t \log p_t(r_t)$: насколько вероятна выбранная формулировка
Средняя энтропия	$\frac{1}{n}\sum_t e_t$: общая неоднозначность продолжения
Максимальная энтропия	$\max_t e_t$: локальный всплеск неопределённости

Уверенность в токене и истинность утверждения различаются.

Semantic entropy отделяет смысл от формулировки

Ответы на один вопрос, учебный пример	Смысл
«Столица — Канберра»; «Это Канберра»; «Канберра»	c_1
«Сидней»	c_2

$$H_{\text{sem}} = -\sum_{c} P(c \mid P) \log P(c \mid P), \qquad \widehat{P}(c \mid P) = \frac{\#\{R_i \in c\}}{K}.$$

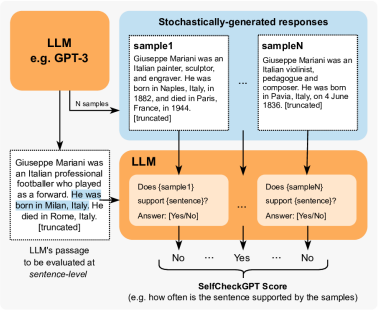
Сначала группируем семантически эквивалентные ответы, затем считаем энтропию кластеров.

Меньше реакции на перефразирование.

Одинаковая ошибка во всех ответах останется незаметной.

Kuhn et al. Semantic Uncertainty. ICLR 2023.; Farquhar et al. Detecting hallucinations using semantic entropy. Nature 2024.

SelfCheckGPT: ответ согласуется с другими генерациями?



1. Получить основной ответ и K дополнительных.

2. Для каждого утверждения проверить поддержку в дополнительных ответах.

3. Агрегировать несогласие в score.

Варианты сравнения: BERTScore, NLI, LLM-судья.

Нужен только текстовый доступ, но цена растёт с числом генераций

Figure source: Manakul et al. SelfCheckGPT. EMNLP 2023.

Согласованность: что именно сравниваем?

Метод	Что сравниваем	Основное ограничение
SelfCheckGPT	Поддержку утверждений в ответах	Дополнительные генерации и судья
Semantic entropy	Распределение смысловых кластеров	Качество кластеризации
INSIDE	Спектр ковариации hidden states ответов	Нужен white-box доступ
Semantic density	Плотность около ответа в семантическом пространстве	Нужны выборки и мера близости

Общий предел

Систематическая ошибка может быть очень согласованной.

Manakul et al. SelfCheckGPT. EMNLP 2023. Kuhn et al. Semantic Uncertainty. ICLR 2023.; Farquhar et al. Detecting hallucinations using semantic entropy. Nature 2024.
Chen et al. INSIDE. ICLR 2024; Qiu, Miikkulainen. Semantic Density. NeurIPS 2024.

Что выберете для своего сервиса?

У нас только текстовый API.

Ответ нужен быстро.

Цена пропущенной ошибки высока.

Обсудим 2 минуты

Где потратить бюджет: на дополнительные генерации,
на проверку источника или на передачу человеку?

Единственного ответа нет: решение зависит от типа ошибок и доступной проверки.

Детектор: качество, доступ и стоимость

$R \sim p_\theta(\cdot \mid P), \quad s(P, R) \in \mathbb{R}$ — score риска галлюцинации.

Больший score означает больший риск; это ещё не вероятность ошибки.

Сигнал / пример	Доступ	Цена и ограничения
Consistency [1]	Ответы модели	Несколько генераций, сравнение ответов
Logits / entropy [2]	Вероятности токенов	Одна генерация, косвенный сигнал
Probe [3]	Hidden states	Разметка и обучение детектора
Attention / TOHA [4]	Матрицы внимания	Одна генерация; отбор голов по разметке

[1] Manakul et al. SelfCheckGPT: Zero-Resource Black-Box Hallucination Detection for Generative Large Language Models. EMNLP 2023.

[2] Fomicheva et al. Unsupervised Quality Estimation for Neural Machine Translation. TACL 2020.

[3] Azaria, Mitchell. The Internal State of an LLM Knows When It's Lying. Findings EMNLP 2023.

[4] Bazarova et al. Hallucination Detection in LLMs with Topological Divergence on Attention Graphs. ACL 2026.

Hidden states: обучаем probe на метках ошибок

$$\hat{q}(P,R) = \sigma\Big(w^\top h(P,R) + b\Big).$$

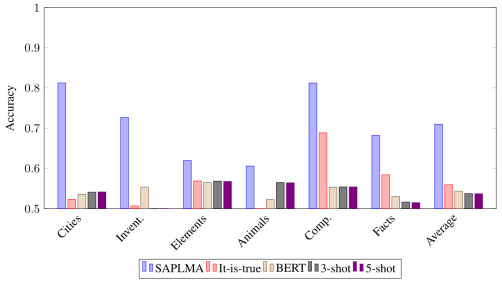
h — выбранное или агрегированное скрытое представление.

Обучение

Корректные и некорректные утверждения задают метки.

Проверка

Новые темы, новые шаблоны, другая модель и длина ответа.



SAPLMA: результаты на отдельных темах.

Figure source: Azaria, Mitchell. The Internal State of an LLM Knows When It's Lying. Findings EMNLP 2023.

Риск можно оценить ещё до генерации

Pre-generation detection

Детектор получает hidden states запроса до первого токена ответа.

$$\hat{q}(P) = \frac{1}{K} \sum_{k=1}^{K} \mathbf{1}\{R_k \text{ содержит ошибку}\}, \quad R_k \sim p_\theta(\cdot \mid P).$$

При обучении

Несколько ответов на запрос дают мягкую метку риска вместо одной случайной метки.

При применении

Probe оценивает риск по запросу: выбираем проверку или другую модель.

Оцениваем частоту будущих ошибок при данном протоколе генерации.

Miftakhova, Zaytsev. Pre-Generation Hallucination Detection via Soft-Target Attention Probing. препринт 2026.

Lookback Lens: внимание к контексту и к своему ответу

$$\mathrm{LR}_{\ell,h,t} = \frac{m_C}{m_C + m_R}, \quad m_C = \frac{1}{|C|}\sum_{j \in C} \alpha_{tj}^{\ell h}, \quad m_R = \frac{1}{|R_{<t}|}\sum_{j \in R_{<t}} \alpha_{tj}^{\ell h}.$$

C — исходный контекст, $R_{<t}$ — уже сгенерированный ответ.

Признаки

Отношения внимания по слоям и головам, усреднённые по фрагменту ответа.

Детектор

Обучаем классификатор контекстных галлюцинаций по этим признакам.

Даже простое распределение внимания несёт сигнал

Chuang et al. Lookback Lens. EMNLP 2024.

Зачем изучать внутренние механизмы

Механистическая интерпретируемость активно развивается:

от отдельных attention heads к цепочкам вычислений в современных LLM.

Понять и проверить механизм

Какие компоненты используют контекст? Как вмешательство в них меняет ответ и уверенность?

Использовать это знание

Объяснить сбой метрики и построить более точную оценку риска.

2022: induction heads

In-context Learning and Induction Heads
Olsson et al. · Transformer Circuits

2025: circuit tracing

On the Biology of a Large Language Model
Lindsey et al. · Transformer Circuits
Планирование, рассуждения и галлюцинации в Claude 3.5 Haiku.

Olsson et al. In-context Learning and Induction Heads. Transformer Circuits, 2022.
Lindsey et al. On the Biology of a Large Language Model. Transformer Circuits, 2025.

От нейронов к признакам: sparse autoencoders

$$f(x) = \mathrm{ReLU}(W_{\mathrm{enc}}x + b), \qquad \hat{x} = W_{\mathrm{dec}}f(x) + b_{\mathrm{dec}}.$$

$$\mathcal{L} = \|x - \hat{x}\|_2^2 + \lambda\|f(x)\|_1.$$

x — активация модели. Разреженный код $f(x)$ активирует мало признаков.

В Claude 3 Sonnet нашли интерпретируемые признаки,
включая понятия, общие для разных языков и форматов.

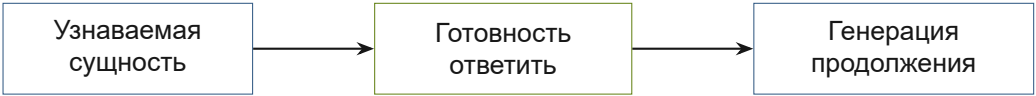
Что это даёт

Можно искать компоненты вычисления и проверять их вмешательствами.

Признак не обязан совпадать с отдельным нейроном. Реконструкция неполна.

Templeton et al. Scaling Monosemanticity. Transformer Circuits, 2024.

Circuit tracing: узнавание имени может снять отказ



Наблюдение в Claude 3.5 Haiku

Узнавание сущности может подавлять механизм отказа.

Возможный сбой

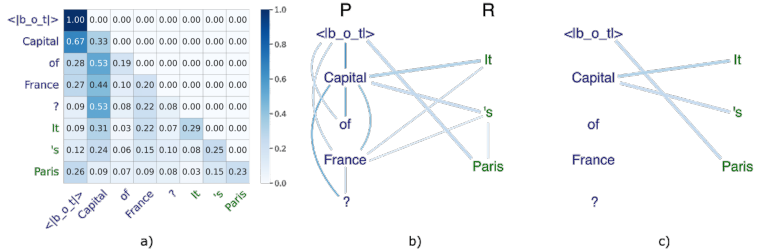
Имя знакомо, но требуемый факт о нём неизвестен.

Вмешательство в признаки меняло склонность отвечать. Это исследование отдельных механизмов, не универсальная карта всех вычислений.

Схема адаптирована по Lindsey et al. On the Biology of a Large Language Model. Transformer Circuits, 2025.

TOHA: attention-матрица задаёт граф

$$A^{\ell h} = \mathrm{softmax}\left(\frac{Q^{\ell h}(K^{\ell h})^{\top}}{\sqrt{d_k}} + M\right), \qquad d_{ij} = 1 - \alpha_{ij}.$$



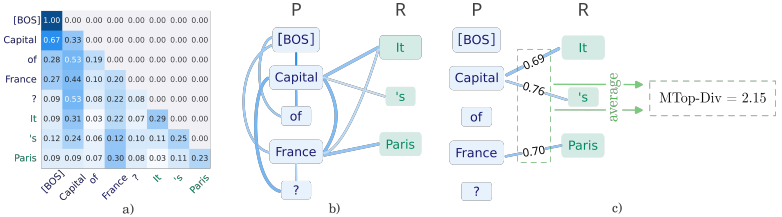
Вершины — токены входа и ответа. Допустимые causal-связи дают рёбра.

Большое внимание соответствует малому весу ребра.

Figure source: Bazarova et al. Hallucination Detection in LLMs with Topological Divergence on Attention Graphs. ACL 2026.

TOHA (ACL 2026): связь ответа с контекстом

Идея: расстояния в attention-графе описывают связь ответа R со входом P.



α_{ij} — вес внимания токена i к токену j в выбранной голове.

$d_{ij} = 1 - \alpha_{ij}$; расстояния внутри P обнуляем.

MTop-Div(R, P) — вес минимального леса, присоединяющего R к P.

Score: средняя по выбранным головам дивергенция, делённая на длину R.

Figure source: Bazarova et al. Hallucination Detection in LLMs with Topological Divergence on Attention Graphs. ACL 2026.
Barannikov et al. Manifold Topology Divergence: a Framework for Comparing Data Manifolds. NeurIPS 2021.

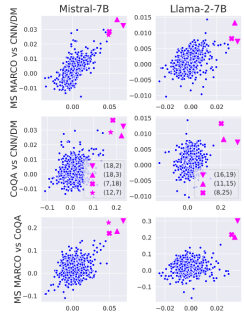
TOHA: отбор голов по размеченным примерам

1. На небольшом probe set считаем дивергенцию в каждой голове.

2. Сравниваем score ошибочных и grounded-ответов.

3. На validation выбираем число голов и агрегируем их score.

Без обучения весов LLM
Но размеченные данные и настройка нужны.



Каждая точка — голова. Сравнение её информативности на двух наборах.

Figure source: Bazarova et al. Hallucination Detection in LLMs with Topological Divergence on Attention Graphs. ACL 2026.

TOHA: качество на разных задачах

Mistral-7B. AUROC ↑, среднее по пяти разбиениям. Таблица 1 финальной статьи.

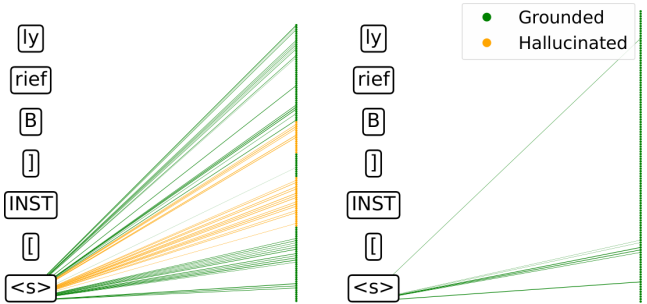
Метод	MS MARCO	CoQA	SQuAD
Max entropy	0.68	0.73	0.75
SelfCheckGPT	0.63	0.86	0.71
TOHA	**0.76**	**0.89**	**0.96**

TOHA использует один ответ; SelfCheckGPT — дополнительные генерации.

Качество зависит от задачи и генератора. Полные сравнения и разброс оценок — в статье.

Bazarova et al. Hallucination Detection in LLMs with Topological Divergence on Attention Graphs. ACL 2026.

TOHA (ACL 2026) выделяет copying heads



Слева: галлюцинация
Сильное внимание к первому токену <s>.

Справа: grounded
Больше связей с содержательным контекстом.

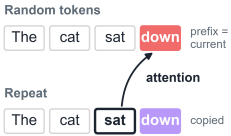
Среди выбранных голов есть top-25 по copying score.

Attention sinks помогают интерпретировать сигнал TOHA

Figure source: Bazarova et al. Hallucination Detection in LLMs with Topological Divergence on Attention Graphs. ACL 2026.
Olsson et al. In-context Learning and Induction Heads. Transformer Circuits, 2022.

Копирующие головы и attention sinks

Induction head



$[A][B] \dots [A] \to [B]$:
голова находит продолжение ранее встречавшегося шаблона.

Attention sink



Многие позиции направляют внимание на один токен, даже если он не важен по смыслу.

Sink часто возникает на начале последовательности или служебном токене.

Для выбранных induction heads он может указывать на отсутствие копирования.

Figure source: Kuleshova et al. INTRYGUE: Induction-Aware Entropy Gating for Reliable RAG Uncertainty Estimation. EMNLP 2026.
Olsson et al. In-context Learning and Induction Heads. Transformer Circuits, 2022.
Xiao et al. Efficient Streaming Language Models with Attention Sinks. ICLR 2024.

Как находят induction heads

Синтетический тест

Подаём случайную последовательность дважды:

$$[x_1, x_2, \ldots, x_L,\ x_1, x_2, \ldots, x_L].$$

$$\text{PrefixMatch}_h = \frac{1}{L-1} \sum_{r=1}^{L-1} \alpha^h_{L+r,r+1}.$$

На втором x_r голова смотрит на токен x_{r+1} после первого x_r.

Для полноценного копирования нужны два свойства

Найти нужную позицию через QK и повысить нужный логит через OV.

Внимание к правильному токену само по себе не доказывает его копирование в выход.

Olsson et al. In-context Learning and Induction Heads. Transformer Circuits, 2022. Kuleshova et al. INTRYGUE: Induction-Aware Entropy Gating for Reliable RAG Uncertainty Estimation. EMNLP 2026.

SinkRate как индикатор активности

$$\text{SinkRate}(A, n) = \max_j \frac{\sum_{i=N-n+1}^{N} \alpha_{ij}}{w_j},$$

$$w_j = \min(n, N - j + 1).$$

$A = (\alpha_{ij})$ — attention-матрица одной головы;
N: длина всей последовательности;
n: число токенов ответа.
Нормировка учитывает causal mask.

Высокий SinkRate
Концентрация на одной позиции; признак слабой induction-активности.

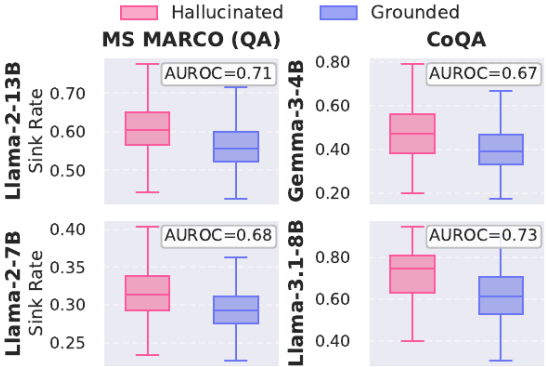


Figure source: Kuleshova et al. INTRYGUE: Induction-Aware Entropy Gating for Reliable RAG Uncertainty Estimation. EMNLP 2026.

Энтропия плохо разделяет ответы

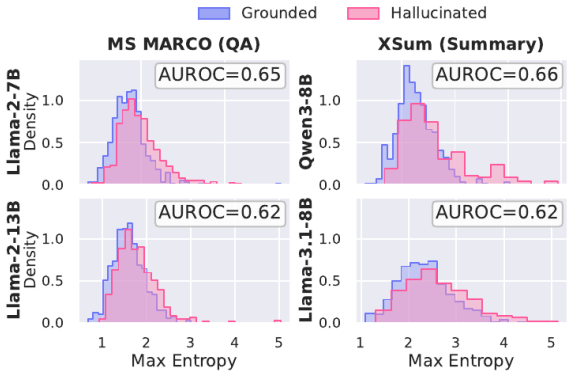
$R = (r_1, \ldots, r_n)$ — токены ответа;
$t = 1, \ldots, n$ — шаг генерации;
$\mathcal{V}$ — словарь токенов модели.

$$p_t(v) = p_\theta(v \mid P, r_1, \ldots, r_{t-1})$$

$$e_t = -\sum_{v \in \mathcal{V}} p_t(v) \log p_t(v), \quad s_{\mathrm{ME}} = \max_t e_t.$$

Максимум выделяет локальный всплеск неопределённости.

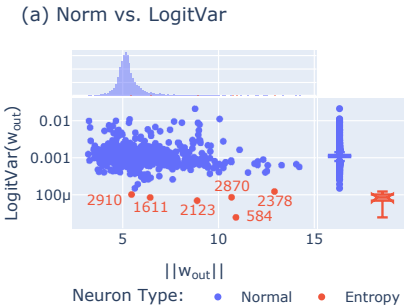
Высокая энтропия бывает и у grounded-ответов.



Здесь AUROC 0.62–0.66: сигнал есть, но распределения сильно пересекаются.

Figure source: Kuleshova et al. INTRYGUE: Induction-Aware Entropy Gating for Reliable RAG Uncertainty Estimation. EMNLP 2026.

Что такое энтропийные нейроны



GPT-2 Small: красным выделены энтропийные нейроны последнего MLP.

Что это

Отдельные компоненты скрытого слоя MLP, влияющие на энтропию предсказания.

Как их находят

Большая норма выходного вектора весов и низкая LogitVar — вариация его прямого вклада в логиты.

Что они делают

Через финальную нормализацию меняют масштаб логитов и уверенность модели.

Figure source: Stolfo et al. Confidence Regulation Neurons in Language Models. NeurIPS 2024.

Нормализация меняет масштаб логитов

Упрощённая модель финальной нормализации, без bias:

$$r(a) = r_0 + aw, \qquad z(a) = \frac{W_U r(a)}{s(r(a))}.$$

$$\frac{dz}{da} = \underbrace{\frac{W_U w}{s}}_{\text{прямой вклад}} - \underbrace{\frac{s'}{s} z}_{\text{изменение масштаба}}.$$

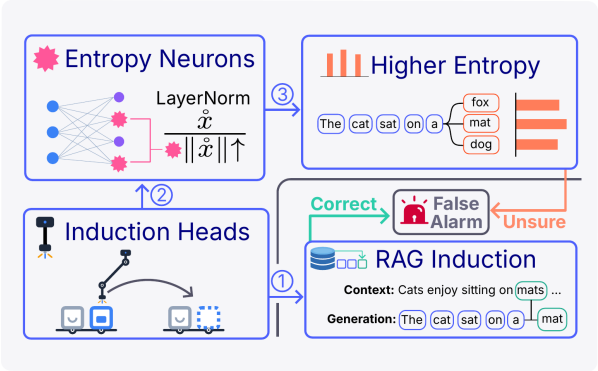
Если прямой вклад мал, а масштаб нормализации растёт, логиты сжимаются и softmax становится менее острым.

Механизм похож на увеличение температуры.

Эффект зависит от направления w и состояния r_0: большая норма сама по себе недостаточна.

Stolfo et al. Confidence Regulation Neurons in Language Models. NeurIPS 2024.

Копирование и энтропийные нейроны



Induction heads
Поддерживают верное продолжение из контекста.

Энтропийные нейроны
Воздействуют на масштаб нормализации; распределение становится менее острым.

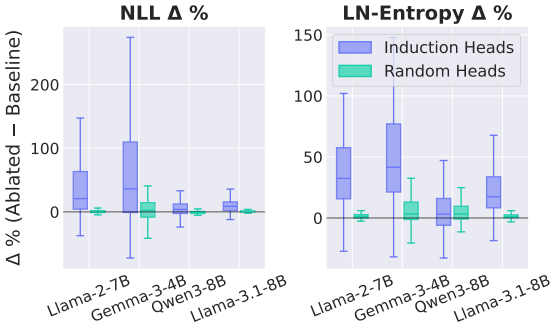
Возможная ложная тревога
Ответ grounded, но энтропия высока.

Figure source: Kuleshova et al. INTRYGUE: Induction-Aware Entropy Gating for Reliable RAG Uncertainty Estimation. EMNLP 2026.

Вмешательство в induction heads

Mean ablation: выход голов заменяем средним; контроль — случайные головы.

NLL — loss правильного ответа; LN-Entropy — средняя энтропия токенов.

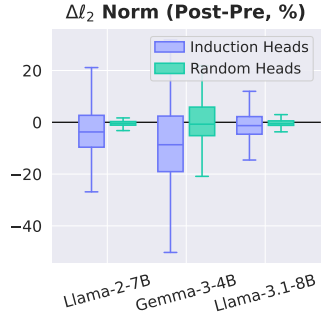


После вмешательства растут NLL и энтропия

Figure source: Kuleshova et al. INTRYGUE: Induction-Aware Entropy Gating for Reliable RAG Uncertainty Estimation. EMNLP 2026.

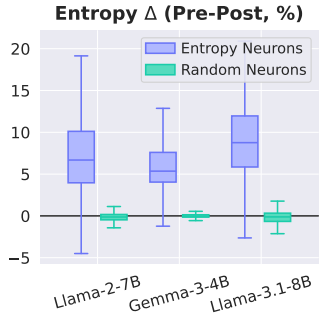
Проверка связи с энтропийными нейронами

Ablation голов



Post $-$ **Pre** < 0**:** активность снижается.

Ablation нейронов



Pre $-$ **Post** > 0**:** энтропия снижается на 5–10%.

Figure source: Kuleshova et al. INTRYGUE: Induction-Aware Entropy Gating for Reliable RAG Uncertainty Estimation. EMNLP 2026.

INTRYGUE (EMNLP 2026): энтропия с gate

H_k — k голов с наибольшим InductionScore на повторяющихся последовательностях; e_t — энтропия на шаге t, n — длина ответа.

$$s(P,R) = \underbrace{f\big(\{\mathrm{SinkRate}_h\}_{h\in H_k}\big)}_{\text{induction gate}} \cdot \underbrace{g\big(\{e_t\}_{t=1}^{n}\big)}_{\text{predictive entropy}} .$$

Низкий SinkRate
Активное копирование уменьшает вес высокой энтропии.

Высокий SinkRate
Сигнал энтропии подавляется слабее.

f: агрегация по головам; g: агрегация по токенам ответа.

Один ответ, без обучения отдельного probe.

Kuleshova et al. INTRYGUE: Induction-Aware Entropy Gating for Reliable RAG Uncertainty Estimation. EMNLP 2026.

Почему min по головам и max по токенам?

$$s_{\text{min,max}} = \min_{h \in H_k} \text{SinkRate}_h \cdot \max_{1 \le t \le n} e_t.$$

Минимум по головам

Одна активно копирующая голова может дать свидетельство использования контекста.

Максимум по токенам

Короткий подозрительный фрагмент не растворяется в длинном ответе.

Это правдоподобная интерпретация, а не доказательство оптимальности.

На CoQA лучше работает mean–mean. Минимум чувствителен к одной аномальной голове, максимум — к длине и редкому токену.

Kuleshova et al. INTRYGUE: Induction-Aware Entropy Gating for Reliable RAG Uncertainty Estimation. EMNLP 2026.

Качество на разных моделях и задачах

6 моделей (4–13B). AUROC ↑, среднее по пяти разбиениям.
Min–max; на CoQA — mean–mean: агрегация по головам и токенам.

	MS MARCO	CNN/DM	CoQA	XSum
Mistral-7B	**0.77**	**0.69**	0.82	**0.73**
Llama-2-7B	**0.72**	0.60*	**0.79**	**0.66**
Llama-2-13B	0.73	**0.60**	**0.81**	**0.63**
Llama-3.1-8B	—	—	0.81	**0.66**
Qwen3-8B	—	—	**0.80**	0.68
Gemma-3-4B	—	—	**0.76**	**0.62**

Зелёным — лучший результат (включая ничью) среди сравниваемых методов.

* Для Llama-2-7B / CNN/DM mean-вариант даёт 0.62. Прочерк — конфигурация не оценивалась.

Комбинация сильнее отдельных сигналов

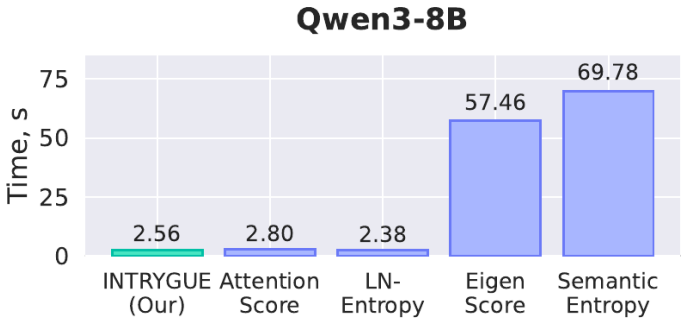
AUROC ↑. Одинаковый вариант INTRYGUE min–max во всех строках.

Задача	Модель	SinkRate	MaxEntropy	INTRYGUE
MS MARCO	Mistral-7B	0.73	0.67	**0.77**
	Llama-2-7B	0.70	0.65	**0.72**
	Llama-2-13B	0.72	0.62	**0.73**
CoQA	Llama-2-13B	0.64	0.65	**0.72**
	Qwen3-8B	0.57	0.73	**0.77**
	Gemma-3-4B	0.63	0.70	**0.73**

Сочетание сигналов улучшает детекцию в этих конфигурациях

Kuleshova et al. INTRYGUE: Induction-Aware Entropy Gating for Reliable RAG Uncertainty Estimation. EMNLP 2026.

INTRYGUE (EMNLP 2026): стоимость детекции



2.56 с
INTRYGUE

2.38 с
LN-Entropy

Детекция без дополнительных генераций.

Qwen3-8B, XSum: 20 примеров, усреднение по 10 запускам.

Возможное ускорение — специальные ядра для извлечения признаков при inference.

Figure source: Kuleshova et al. INTRYGUE: Induction-Aware Entropy Gating for Reliable RAG Uncertainty Estimation. EMNLP 2026.

Границы применимости метода

White-box доступ

Нужны attention weights и logits; обычного текстового API недостаточно.

Копирование — не единственный способ ответить

Рассуждения и короткие ответы «да/нет» могут быть верными при слабой induction-активности.

Контекст и порог требуют проверки

Согласованность с документом не гарантирует его истинность.

Порог детектора настраивается на целевой задаче под цену ошибки.

Детектор становится полезен внутри контура проверки

Наблюдение	Действие системы	Проверка результата
Контекста мало	Найти новые документы	Появились нужные сведения?
Ответ не опирается на источник	Проверить утверждения и цитаты	Источник подтверждает тезис?
Риск остаётся высоким	Отказ или передача человеку	Запрос разрешён корректно?
Много повторяемых ошибок	Разметка и дообучение	Улучшение на новом тесте?

Нужны бюджет и условие остановки повторных попыток.

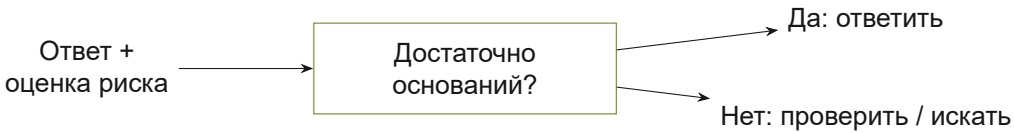
Адаптивный RAG: когда стоит искать ещё?

Фиксированный RAG

Один и тот же объём поиска для простого и сложного запроса.

Адаптивный RAG

Риск и доступные свидетельства определяют, нужен ли дополнительный поиск.



Дополнительный поиск оправдан, если ожидаемая польза превышает его цену.

Moskvoretskii et al. Adaptive Retrieval Without Self-Knowledge? Bringing Uncertainty Back Home. ACL 2025.

Байесовский агент: beliefs, наблюдения, действия

z — неизвестное состояние задачи, h_t — история, a_t — действие, o_{t+1} — результат.

$$b_{t+1}(z) \propto p(o_{t+1} \mid z, a_t, h_t)\, b_t(z).$$

$$a_t^* = \arg\max_a \; \mathbb{E}_{z \sim b_t}[U(a, z)] - C(a).$$

Контроллер хранит и обновляет предположения.

Тест, поиск или эксперт дают наблюдение. Его информативность влияет на следующий шаг.

Байесовские принципы относятся к оркестрации.

Саму LLM можно использовать как обычный генератор или инструмент.

Papamarkou et al. Position: Agentic AI Orchestration Should Be Bayes-Consistent. ICML 2026.

Учебный пример: ответить или проверить?

Вероятность верного ответа после калибровки $q = 0.85$.
Цена ошибки 100, цена проверки 3. После проверки остаточный риск 0.02.

$$L(\text{ответить}) = (1 - 0.85) \cdot 100 = 15.$$
$$L(\text{проверить}) = 3 + 0.02 \cdot 100 = 5.$$

В этих условиях проверка выгоднее.

Если цена ошибки равна 1, потери от ответа 0.15,
а от проверки 3.02. Решение меняется.

Учебный пример по мотивам Papamarkou et al. Position: Agentic AI Orchestration Should Be Bayes-Consistent. ICML 2026.

Несколько агентов не равны независимым экспертам

Пять согласных ответов могут иметь
один и тот же источник ошибки.

- Общая модель, документы и prompt создают зависимость.
- Новый ответ полезен, если приносит дополнительное свидетельство.
- Тест кода или найденный первоисточник может быть ценнее ещё одного голосования.

Правило остановки

Продолжаем, пока ожидаемое улучшение решения больше цены следующего шага.

Papamarkou et al. Position: Agentic AI Orchestration Should Be Bayes-Consistent. ICML 2026.

Неопределённость помогает распределять бюджет обучения

Complexity-Aware Fine-Tuning
Тратить дорогую генерацию рассуждений на трудные примеры.

Идея
Оценить сложность, выбрать режим подготовки данных, дообучить модель.

Проверять и качество, и число обработанных токенов.

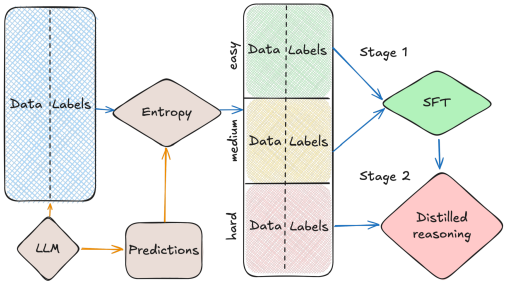


Figure source: Goncharov et al. Complexity-Aware Fine-Tuning. Findings EACL 2026.

Как проверять пользу детектора в своём RAG

1. Определить ошибку и единицу разметки: факт, фрагмент или ответ.
2. Разделить настройку и тестирование, проверить новые темы и источники.
3. Сравнить простые baseline: entropy, consistency, проверку источника.
4. Выбрать порог по risk–coverage и цене ошибок.
5. Измерить качество всего процесса вместе с задержкой и стоимостью.

Работы лаборатории и совместные исследования

ТОНА · ACL 2026

Hallucination Detection in LLMs with Topological Divergence on Attention Graphs

INTRYGUE · EMNLP 2026

Induction-Aware Entropy Gating for Reliable RAG Uncertainty Estimation

Bayes-consistent orchestration · ICML 2026

Position: Agentic AI Orchestration Should Be Bayes-Consistent

Pre-generation detection · препринт 2026

Pre-Generation Hallucination Detection via Soft-Target Attention Probing

Complexity-Aware Fine-Tuning · Findings EACL 2026

Complexity-Aware Fine-Tuning

Статусы и ссылки проверены 14 октября 2026 года.

Можно ли доверять ИИ? Выводы

Сначала определяем ошибку.
Истинность и соответствие источнику требуют разных проверок.

Сочетаем несколько сигналов.
Неопределённость, согласованность и внутренние механизмы дают разные свидетельства.

Связываем риск с действием.
Проверяем, ищем, отвечаем или останавливаемся с учётом цены ошибки.

Спасибо! Перейдём к обсуждению.

Мой канал

@search_of_time

Курсы

genmod.ai

Обсуждаем ИИ
и учимся строить агентов.